

Определения:

C_{in} - число входных каналов

C_{out} - выходных каналов

K - размер ядра свертки (k, k)

S - размер шага (стрейд)

S_{out} - размер изображения на выходе


S_{in} - размер на входе $(S_{in} \times S_{in})$

B - размер батча

pad - размер padding $(pad = \frac{K}{2})$



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ



По определению свёртки в ячейке выходной матрицы находится рез-т суммы поэлементного произведения соответствующего участка изображения размером $K \times K$ с ядром свёртки размером $K \times K$.

Тогда, чтобы определить число выходных "пикселей" по оси, нужно посчитать сколько раз применится ядро свёртки ко входной матрице вдоль оси, не выходя за её пределы.

Из схемы видно, что кол-во применений ядра свёртки ко входу вдоль оси = $1 + \text{кол-во шагов ядра вдоль оставшейся после первого применения части входной матрицы}$.

$$S_{out} = 1 + \frac{S_{in} + 2 \cdot pad - K}{S}$$




НАСТРОЙ СВОЙ
 МАРКЕТИНГ
 НА МАКСИМУМ

Теперь посчитаем для каждого слоя размер его выхода и кол-во эл-тов на 1 сэмпл.

Замечание:

1. Кол-во элементов и выходной размер для операции пуллинга считается также как и для свёртки.
2. Функции активации размер не меняют.

Layer	S_{in}	$C_{in} \rightarrow C_{out}$	S_{out}	Elements
Conv 7x7 S2	S_{in}	$3 \rightarrow 32$	$S_{in}/2$	$32(S_{in}/2)^2 = 8S^2$
Maxpool 3x3 S2	$S_{in}/2$	$32 \rightarrow 32$	$S_{in}/4$	$32 \cdot (S_{in}/4)^2 = 2S^2$
Conv 5x5	$S_{in}/4$	$32 \rightarrow 64$	$S_{in}/4$	$64(S_{in}/4)^2 = 4S^2$
Conv 3x3 S2	$S_{in}/4$	$64 \rightarrow 128$	$S_{in}/8$	$128(S_{in}/8)^2 = 2S^2$
Conv 1x1	$S_{in}/8$	$128 \rightarrow 256$	$S_{in}/8$	$256(S_{in}/8)^2 = 4S^2$
Conv 3x3 S2	$S_{in}/8$	$256 \rightarrow 256$	$S_{in}/16$	$256(S_{in}/16)^2 = S^2$
Conv 1x1	$S_{in}/16$	$256 \rightarrow 512$	$S_{in}/16$	$512(S_{in}/16)^2 = 2S^2$
Global AVG	$S_{in}/16$			512
FC 512 $\rightarrow$ 256				256
FC 256 $\rightarrow$ 100				100



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ

FLOPS

Для получения 1-го числа в выходной матрице из слоя свертки необходимо совершить $2 \times K \times K$ операций сложения и умножения.

Тогда с учётом того, что изображение и выход многоканальные: $2 \times K^2 \times C_{in} \times C_{out}$

layer	C_{in}	C_{out}	$\alpha =$	S_{out}	$\alpha = C_{out} \times C_{in} \times 2 \times K^2 / Z^2$
Conv 7×7	3	32	2	$S/2$	$32 \times 3 \cdot 49 \cdot 2/4 = 2334$
Maxpool 3×3	32	32	4	$S/4$	$672 \cdot 4/16 = 168$
Conv 5×5	32	64	4	$S/4$	$672 \cdot 4/16 = 168$ 6400
Conv 3×3	64	128	8	$S/8$	2304
Conv 1×1	128	256	8	$S/8$	$256 \times 128 \cdot 2 \cdot 1/64 = 1024$
Conv 3×3	256	256	16	$S/16$	4608
Conv 1×1	256	512	16	$S/16$	1024
Global AVG	512	512			0
FC $512-256$	512	256			$const = 512 \cdot 256 = 131k$
FC $256-100$	256	100			$const = 256 \cdot 100 = 256k$

Итоговый FLOPS сети = сумма FLOPS отдельных слоев.

α - вклад в FLOPS; $FLOPS = \alpha \cdot S_{in}^2$



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ

Z - коэф-т пропускания.
т.е. Выход слоя имеет размер
 $S/4, Z = 4$.

Тогда итоговая формула FLOPS будет

$$FLOPS(B, S_{in}) = B \cdot (17712 \cdot S_{in}^2 + 313344)$$

Допущения: 1. операции пуллинга дают
значительно меньший вклад во FLOPS
относительно остальных слоев, поэтому
их не учитывал

2. Операции от активаций и Batch Norm
также незначительны и не учтены.

Т.е. во FLOPS учтены операции из
сверточных и полносвязных слоев

Память:

Память = $M_{params} + M(t)$, где $M(t)$ - размер памяти под "кубы" активации

Допущения:

1. Новый куб создается до того, как освободится вход.
2. Входной тензор куб на протяжении работы всего forward-pass'a может
3. Память не освобождается сразу после использования. Поэтому для пиковой памяти считаем не max по времени потребляемой памяти, а sum.

Тензор	Форма	Элементов	Байт
X (вход)	$3 \cdot S \cdot S$	$3 S^2$	$12 S^2$
a_1 (conv, out)	$32 \cdot S/2 \cdot S/2$	$8 S^2$	$32 S^2$
p (pool, out)	$32 \cdot S/4 \cdot S/4$	$2 S^2$	$8 S^2$
a_2 (conv, out)	$64 \cdot S/4 \cdot S/4$	$4 S^2$	$16 S^2$
a_3 (conv, out)	$128 \cdot S/8 \cdot S/8$	$2 S^2$	$8 S^2$
a_4	$256 \cdot S/8 \cdot S/8$	$4 S^2$	$16 S^2$
a_5	$256 \cdot S/16 \cdot S/16$	S^2	$4 S^2$
a_6	$512 \cdot S/16 \cdot S/16$	$2 S^2$	$8 S^2$
g (GAP)	512	512	2048
h_1, h_2 (FC ₁ → FC ₂)	$256 + 100$	$256 + 100$	1424



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ

FP32 → 4 байта

$$\sum M(t) = (12 + 32 + 8 + 16 + 8 + 16 + 4 + 8) S^2 + 3472 =$$

$$= 104 S^2 + 3472 \text{ байт}$$

Память на параметры модели -
 - для сверточного слоя нужна память
 под $C_{in} \cdot C_{out} \cdot K^2$ элементов.

- для полносвязного слоя нужна
 память под $n_{in} \cdot n_{out}$ элементов.

Тогда просуммировав по всей сети
 кол-во весов модели $(M_{conv 7 \times 7} + \dots +$
 $+ M_{conv 1 \times 1} + M_{fc 256 \rightarrow 100})$ получим

$$M_{params} = 1040324 \text{ элемента}$$

Итого:

$$Memory(B, S) = (104 S^2 + 3472) \cdot B +$$

$$+ 1040324 \cdot 4 = (104 S^2 + 3472) B + 4,16 \cdot 10^6 \text{ байт}$$

Bytes Moved

- это суммарный трафик, который должен прочитаться / записаться ровно 1 раз.

$$= \sum_{\text{слои}} [\text{прочитанные входы} + \text{прочитанные веса} + \text{записанные выходы}]$$

Допущения:

1. Каждый слой читает из памяти и пишет в нее 1 раз.
2. Веса читаются один раз за проход
3. In place операции все равно двигают байты

Ранее по памяти уже вычислялись размеры входов и выходов для операций.

Здесь просто напомним:

Слой 1 читает $x = 3S^2$ и пишет $8S^2$ - это суммарно $11S^2$ прочитанных / записанных эл-в.

$$\begin{aligned} \sum \text{прочитанных / записанных} &= (11 + 10 + 6 + 6 + 6 + 5 + \\ &+ 3 + 2) \cdot S^2 + \underbrace{768}_{\text{FC}_1} + \underbrace{512}_{\text{Relu}} + \underbrace{356}_{\text{FC}_2} + \underbrace{512}_{\text{GAP}} = 49S^2 + 2148 \end{aligned}$$

элементов

$$\sum \text{bytes Moved} = 4 \cdot (49S^2 + \overset{2148}{\cancel{2148}} + \underbrace{1040324}_{\text{веса}})$$



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ

$$\text{Bytes}(S, B) = B(196S^2 + 8592) + 4,16 \cdot 10^6 \text{ байт}$$

FP32 = 4 байт

⑧

Latency:

$$T = \max(T_{\text{launch}}, T_{\text{mem}}, T_{\text{compute}})$$

Общая задержка - максимум от задержек отдельных шагов вычислений.

Задержка зависит в т.ч. от характеристик железа и эффективности/доступности этих заявленных пиковых характеристик

$$T_{\text{launch}} = \Theta_0$$

$$T_{\text{mem}} = \text{BytesMoved}(S, B) / \eta_{\text{mem}} \cdot \text{BW}_{\text{peak}}$$

$$T_{\text{compute}} = \text{FLOPS}(S, B) / \eta_{\text{compute}} \cdot \text{FLOPS}_{\text{peak}}$$

BW_{peak} и $\text{FLOPS}_{\text{peak}}$ - заявленные в хар-к железа пиковые пропускная способность памяти и производительность процессора

η_{mem} - безразмерная эффективность памяти

η_{compute} - эффективность производительности относительно паспортных значений

Θ_0 - время на запуск ядер, синхронизации и всё остальное, что не зависит от S и B

$$T(S, B, \Theta) = \max\left(\Theta_0, \frac{\text{BytesMoved}(S, B)}{\eta_{\text{mem}} \cdot \text{BW}_{\text{peak}}}, \frac{\text{FLOPS}(S, B)}{\eta_{\text{compute}} \cdot \text{FLOPS}_{\text{peak}}}\right)$$

$$\text{FLOPS}(S, B) = B \cdot (17712 \cdot S^2 + 313344)$$

$$\text{BytesMoved}(S, B) = B \cdot (196S^2 + 8592) + 4,16 \cdot 10^6$$



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ

$$= B \cdot (196S^2 + 8592) + 4,16 \cdot 10^6$$

Допущения

1. Сноу выполняются без перекрестий
2. V_{max} , V_{compute} - постоянны и не зависят от сноу и S, B
3. Весь трафик идёт из/в память без кэшей

Энергия:

Энергия - это интеграл мощности за время прохода. Она распадается на:

- Статическую часть (P_{idle}) - токи утечки и прочее, что есть всегда, пока процессор включен и не зависит от того, что мы делаем - она даёт вклад $P_{idle} \cdot T$, где T - время `forward pass'a`
- Динамическая часть - переключение транзисторов за выполненную работу.

$$E = P_{idle} \cdot T + E_{dyn}$$

Динамическая часть рассчитывается для арифметических операций и для перемещения данных, и каждая из них имеет свою цену за операцию


$$E_{dyn} = e_{flop} \cdot FLOPS(S, B) + e_{byte} \cdot BytesMoved(S, B)$$

Итого:

$$\begin{aligned} E(S, B, \theta) &= P_{idle} \cdot T(S, B, \theta) + e_{flop} \cdot FLOPS(S, B) + \\ &+ e_{byte} \cdot BytesMoved(S, B) = P_{idle} \cdot T(S, B, \theta) + \\ &+ e_{flop} \left(B \cdot (17712 S^2 + 313344) \right) + \\ &+ e_{byte} \left(B \cdot (196 S^2 + 8592) + 4,16 \cdot 10^6 \right) \quad D_x \end{aligned}$$

e_{flop} - энергия на 1 арифм. операцию

e_{byte} - энергия на 1 перемещенный байт в памяти



НАСТРОЙ СВОЙ
МАРКЕТИНГ
НА МАКСИМУМ

(11)

Допущения:

1. Энергия расходуется на статику и динамику. А динамика линейна от работы.
2. R_{floor} , R_{cyl} - постоянны и не зависят от скорости, размера входа.
3. ~~Энергия на Wait~~ P_{idle} - постоянна.
4. Не учитываем охлаждение, питание платы и т.д.